



Atividade 4 - Árvores de Decisão e Florestas Aleatórias

Ferramentas: Utilize o notebook Python da aula como base para realizar as tarefas a seguir.

Parte 1: Aplicando a Floresta a um Novo Desafio (O Dataset Iris)

Nesta parte, você irá aplicar exatamente a mesma metodologia da aula, mas em um novo dataset clássico: o **Iris**, que busca classificar 3 espécies de flores com base nas medidas de suas pétalas e sépalas.

Instruções:

1. Crie uma cópia do notebook da aula para não alterar o original.

No início do código, substitua o carregamento do dataset de câncer pelo dataset Iris.

O código para isso é:

```
from sklearn.datasets import load_iris
# Carregando o dataset Iris
iris = load_iris()
X = pd.DataFrame(iris.data, columns=iris.feature_names)
y = pd.Series(iris.target).map({0: 'Setosa', 1: 'Versicolor', 2: 'Virginica'})
```

2. Execute o restante do notebook, passo a passo:
 - Divida os dados em treino e teste.
 - Treine uma **única Árvore de Decisão**.
 - Treine uma **Floresta Aleatória**.
 - Gere e analise as acurácias e as matrizes de confusão.
 - Gere o gráfico de importância das features.

Perguntas a Responder (você pode utilizar uma célula do notebook):

1. A única Árvore de Decisão sofreu overfitting neste novo dataset? Compare as acurácias de treino e teste para justificar sua resposta.
2. A Floresta Aleatória teve um desempenho superior ao da única árvore no conjunto de teste?
3. De acordo com o gráfico gerado, qual foi a característica mais importante que o modelo usou para classificar as espécies de flores?



Parte 2: Ajustando os Parâmetros da Floresta (Hiperparâmetros)

Agora, volte a usar o **dataset original de Câncer de Mama**. O objetivo é investigar o efeito de dois parâmetros muito importantes do RandomForestClassifier.

Tarefa 2.1: O Efeito do Número de Árvores (n_estimators)

1. Crie um laço for ou teste manualmente a RandomForestClassifier com diferentes valores para o parâmetro n_estimators. Sugestão de valores: [1, 10, 20, 50, 100, 200].
2. Para cada valor, treine um novo modelo e anote a **acurácia no conjunto de teste**.

Pergunta a Responder:

4. O que acontece com a acurácia à medida que aumentamos o número de árvores na floresta? A performance melhora indefinidamente ou chega a um ponto em que o ganho é muito pequeno?

Tarefa 2.2: O Efeito da Profundidade das Árvores (max_depth)

1. Mantenha o número de árvores fixo em n_estimators=100.
2. Agora, teste diferentes valores para o parâmetro max_depth. Sugestão de valores: [1, 2, 3, 5, 10, None].
3. Para cada valor, treine um novo modelo e anote a acurácia tanto no conjunto de **treino** quanto no de **teste**.

Pergunta a Responder:

5. Como o parâmetro max_depth afeta o overfitting? Descreva o que aconteceu com a acurácia de treino e a de teste à medida que a profundidade das árvores aumentou.